AKADEMIA GÓRNICZO-HUTNICZA
im. Stanisława Staszica w Krakowie
WYDZIAŁ ZARZĄDZANIA

Przedmiot: **Ekonometria finansowa i dynamiczna**

Projekt: **4B, wersja A**

Autorzy: Małgorzata Leszczyńska, Jakub Laszczyk, Aleksandra Wajda, Mateusz Chojecki

Informatyka i Ekonometria
2 rok studia magisterskie niestacjonarne,
grupa laboratoryjna 1

Kraków, 16 listopada 2025 r.

Polecenie

Projekt 4B, wersja A

Do całego szeregu czasowego (bez ostatniej obserwacji) dopasować odpowiedni model ARMA z dołożonym modelem uwzględniającym możliwy efekt ARCH. Zweryfikować jego poprawność. Zwrócić szczególną uwagę na zgodność z wybranym rozkładem warunkowym. Wyznaczyć 95% przedział ufności dla następnej stopy zwrotu i sprawdzić, czy rzeczywista dana znajduje się w tym przedziale. Na podstawie odpowiedniego rozkładu warunkowego obliczyć prawdopodobieństwo, że następna stopa zwrotu będzie ujemna. Rozważyć następujące modele warunkowej wariancji: GARCH, EGARCH, GJR-GARCH, każdy z trzema różnymi rozkładami warunkowymi.

Analizę analogiczną jak w części A przeprowadzić w przesuwanych oknach o długości 100, 200 i 500 obserwacji. Jako koniec pierwszego okna przyjąć ostatnią obserwację w 2018 roku. Wybór rzędów opóźnień w modelu ARMA wystarczy przeprowadzać na początku każdego roku (podać zestawienie wybranych modeli). Zbadać przypadki, gdy następna obserwacja nie wpadała do wyznaczonego przedziału ufności (obliczyć odsetek takich przypadków, czy występują w jakichś konkretnych momentach, więcej jest za niskich/ za wysokich wartości, itp.). Czy zastosowany model GARCH i wybrany rozkład warunkowy mają wpływ na odsetek przypadków, gdy następna obserwacja nie znajdowała się w wyznaczonym przedziale ufności? Czy składniki losowe oszacowanych modeli miały wybrany rozkład warunkowy? Jak ta zgodność z rozkładem zmieniała się w czasie? Jak zmieniało się w czasie prawdopodobieństwo spadku w trakcie następnego dnia (ujemna następna stopa zwrotu). Jak często (i ew. kiedy) prawdopodobieństwo spadku większe niż 0,5 było potwierdzone rzeczywistym spadkiem wartości rozważanego instrumentu?

Cel projektu

Analiza finansowych szeregów czasowych wymaga modeli, które poza dynamiką średniej (ARMA) uwzględniają również zmienność wariancji w czasie, czyli efekt ARCH.

Projekt koncentruje się na dopasowaniu i weryfikacji poprawności takiego połączonego modelu. Porównane zostaną różne specyfikacje dla warunkowej wariancji (GARCH, EGARCH, GJR-GARCH) oraz trzy różne rozkłady warunkowe, aby znaleźć najlepsze dopasowanie do danych.

Finalny model posłuży do prognozy jednokresowej, w ramach której wyznaczony zostanie 95% przedział ufności dla następnej stopy zwrotu oraz obliczone prawdopodobieństwo straty (ujemnej stopy zwrotu). Prognoza ta zostanie następnie zweryfikowana z rzeczywistą, ostatnią obserwacją szeregu.

Opis danych

Podstawę projektu stanowią dane historyczne w postaci szeregu czasowego dla indeksu WIG20, który grupuje 20 największych oraz najbardziej płynnych spółek notowanych na Giełdzie Papierów Wartościowych w Warszawie.

Surowe dane, pochodzące z pliku wig20_d.csv (przy dopasowaniu modelu z przesunięciami wykorzystywany jest plik wig20_d_part_b.csv), obejmują następujące informacje dla każdej sesji giełdowej:

- Cena otwarcia
- Cena maksymalna
- Cena minimalna
- Cena zamknięcia
- Wolumen obrotu

Okres badawczy dla dopasowania bez przesunięć obejmuje notowania dzienne od 2 stycznia 2017 r. do 14 listopada 2025 r. W sumie analizie poddano 2218 obserwacji (sesji giełdowych). Dla dopasowań z przesunięciami okres obejmuje dane dzienne od 4 stycznia 2016 r. do 14 listopada 2025 r, w sumie 2469 obserwacji.

Warunkowa wartość oczekiwana i warunkowa wariancja

Jak wiadomo, dane finansowe nie są niezależne ani nie mają warunkowej wariancji. Często występuje tzw. klasteryzacja zmienności (są okresy dużej i okresy małej zmienności). Z tego powodu w analizie finansowej stosuje się warunkową wartość oczekiwaną i warunkową wariancję, które uwzględniają wpływ poprzednich informacji na kolejną obserwację. Warunkową średnią w projekcie modelujemy za pomocą ARMA, natomiast warunkową wariancję badamy modelami GARCH.

Klasteryzację zmienności widać na wykresach logarytmicznych stóp zwrotu, a w tym projekcie została ona formalnie zbadana testem LM, którego hipoteza zerowa mówi o braku efektów ARCH. Hipoteza alternatywna mówi, że efekt ARCH występuje. W przypadku badania danych w tym projekcie, p-value dla tego testu jest poniżej poziomu istotności (0,05), co pozwala odrzucić hipotezę zerową. Na podstawie tego wyniku zasadna jest dalsza analiza pod kątem efektu ARCH.

Model GARCH

1. GARCH: Model symetryczny

Działanie modelu GARCH(1,1) opiera się na założeniu, że dzisiejsza wariacja jest średnią ważoną trzech składników:

1. ω (omega): Stała, poziom wariancji (zawsze dodatni), do której model "wraca". Jeśli ω jest bliskie zera, oznacza to, że zmienność w głównej mierze wynika z poprzednich obserwacji.
2. $\alpha\ u^2_{t-1}$ (składnik ARCH): Wpływ wczorajszego szoku (błędu). α to waga, jaką model przykłada do tej "nowej informacji".
3. $\beta\ \sigma^2_{t-1}$ (składnik GARCH): Wpływ wczorajszej prognozy wariancji. β to waga "starej informacji", która pokazuje, jak bardzo zmienność jest trwała.

$$\sigma_t^2 = \omega + \alpha\ u^2_{t-1} + \beta\ \sigma^2_{t-1},$$

Kluczowa cecha (i wada): symetria. Model używa kwadratu szoku (u^2_{t-1}). Oznacza to, że szok ujemny (np. spadek -2%) i szok dodatni (np. wzrost +2%) mają dokładnie taki sam wpływ na prognozę przyszłej zmienności. W rzeczywistości rynkowej jest to często nieprawdziwe.

2. EGARCH: Model asymetryczny

Model EGARCH (Wykładniczy GARCH) został zaprojektowany, aby bezpośrednio modelować efekt dźwigni, czyli silniejszą reakcję zmienności na "złe wieści" (spadki) niż na "dobre wieści" (wzrosty). Modeluje on logarytm wariancji ($\log(\sigma_t^2)$). Ma to dwie zalety: prognozy wariancji są zawsze dodatnie (tak samo jak w zwykłym GARCH), a model EGARCH może inaczej reagować na znak szoku. Model EGARCH(1,1) przedstawia wzór:

$$\log(\sigma_t^2) = \omega + \beta \log(\sigma^2_{t-1}) + \alpha\ (|u_{t-1}| / |\sigma_{t-1}|) + \gamma\ (u_{t-1} / \sigma_{t-1})$$

Kluczowa cecha: Asymetria. W równaniu EGARCH znajduje się specjalny parametr (γ, gamma), który mierzy siłę asymetrii. Jeśli $\gamma < 0$ wskazuje to na negatywny szok. Powoduje to większy wzrost przyszłej zmienności niż pozytywny szok o tej samej wielkości. Model ten więc rozdziela wpływ szoku na jego wielkość (jak duży był) i znak (czy był to wzrost, czy spadek).

3. GJR-GARCH: Model asymetryczny

Model GJR-GARCH to alternatywne i bardzo popularne podejście do modelowania warunkowej wariancji. Jest to rozszerzenie standardowego modelu GARCH. Działa tak samo, ale dodaje jeden "karny" składnik, który "włącza się" tylko wtedy, gdy szok jest negatywny. Model GJR-GARCH(1,1) zapisywany jest pod postacią:

$$\sigma_t^2 = \omega + \alpha\ u^2_{t-1} + \gamma\ S_{t-1}\ u^2_{t-1} + \beta\ \sigma^2_{t-1},$$

gdzie $S_{t-1} = 1$, gdy $u_{t-1} < 0$ lub $S_{t-1} = 0$, gdy $u_{t-1} >= 0$

Kluczowa cecha: Asymetria przez zmienną warunkową. Model dodaje do równania parametr γ (gamma) mnożony przez wczorajszy szok (a_{t-1}^2), ale *tylko* jeśli ten szok był ujemny (jeśli $a_{t-1} < 0$). Jeśli wczorajszy szok był pozytywny, to wpływ na zmienność jest mierzony tylko przez α. Jeśli wczorajszy szok był negatywny, to wpływ na zmienność jest mierzony przez $\alpha + \gamma$. Jeśli $\gamma > 0$, oznacza to, że negatywne szoki mają dodatkowy, wzmocniony wpływ na przyszłą zmienność, co jest zgodne z teorią efektu dźwigni.

Dopasowanie modelu ARMA z efektem ARCH - bez przesunięć

W projekcie wczytano dane, obliczono logarytmiczne stopy zwrotu * 100 (szczegóły tej części analizy opisywano w poprzednich projektach, gdzie również charakteryzowaliśmy dane WIG-20). Ostatnia obserwacja została odsunięta jako rzeczywista następna obserwacja używana przy ocenie prognoz.

Następnie wybrano model ARMA. W celu optymalizacji obliczeń ograniczono przeszukiwanie p i q dla wartości od 0 do 3. Kryterium wyboru była minimalna wartość wskaźnika AIC. Wybrany został model ARMA(0, 0) ze stałą, więc nie ma on zerowej wartości oczekiwanej. Stała wynosi tutaj 0,02. Top 10 modelu ARMA (na podstawie AIC) przedstawiono w tabeli.

p	q	AIC	BIC
0	0	7836	7848
2	0	7837	7871
1	2	7837	7865
2	1	7837	7866
1	1	7837	7855
2	2	7837	7855
3	1	7837	7872
3	2	7838	7872
3	0	7838	7866
3	3	7838	7867

Jak wspomniano we wstępie pracy występowanie efektu ARCH zostało potwierdzone testem LM, dlatego następnym krokiem było zastosowanie trzech modeli GARCH do oszacowania warunkowej wariancji: GARCH(1,1), EGARCH(1,1), GJR-GARCH(1,1). Każdy z modeli estymowano trzykrotnie dla różnych rozkładów warunkowych: normalnego, t-studenta, skew-t (skośny t-Studenta), co w sumie dało 9 modeli.

Dla każdego z 9 dopasowanych modeli wyznaczono warunkową wartość oczekiwaną i warunkową wariancję oraz kwantyle służące do zbudowania przedziałów ufności oraz sprawdzono, czy rzeczywista obserwacja w danym momencie t się tam znajduje. Obliczono prawdopodobieństwo, że stopa zwrotu będzie ujemna.

Finalnie przeprowadzono diagnostykę reszt za pomocą testu Ljung-Boxa. Przeprowadzono go dla zestandaryzowanych reszt oraz dla kwadratów reszt. H0: wszystkie autokorelacje są

równe zero (brak autokorelacji), H1: co najmniej jedna autokorelacja jest istotnie różna od zera. Jeżeli p-value jest wyższe niż przyjęty poziom istotności (tutaj 0,05), to nie ma podstaw do odrzucenia hipotezy zerowej.

Powyższy test wykonujemy dla reszt standaryzowanych, ponieważ chcemy dowiedzieć się czy po uwzględnieniu warunkowej zmienności,reszty mają rozkład zbliżony do normalnego. Jeśli standaryzowane reszty nie są normalne, model źle modeluje warunkową dystrybucję. Natomiast test Ljung-Boxa wykonany na kwadratach reszt standaryzowanych sprawdza, czy efekt ARCH dalej występuje (czyli czy model GARCH prawidłowo modeluje warunkową wariancję).

Wyniki dopasowania modelu - bez przesunięć

Finalnie wybrano najlepszy model porównując je za pomocą AIC i BIC. Jak widać w poniższej tabeli, najlepsze wyniki pod kątem kryterium AIC i BIC osiągnął GJR-GARCH przy założeniu rozkładu t-studenta dla reszt.

Model	**Rozkład reszt**	**AIC**	**BIC**	**Warunkowa średnia**	**Warunkowe odch. std.**	**dolny przedział uf. 95%**	**górny przedział uf. 95%**	**prognozowana kolejna wartość**	**prognoza w przedziale uf?**	**kolejna wartość < 0**	**p-value Ljung-Box dla reszt**	**p-value Ljung-Box dla reszt^2**
GJR-GARCH	t	7 339	7 373	0,01	1,02	-2,02	2,04	-0,86	True	0,50	0,52	0,31
GJR-GARCH	skewt	7 341	7 381	0,01	1,02	-2,02	2,04	-0,86	True	0,50	0,52	0,31
GARCH	t	7 375	7 403	0,03	1,08	-2,12	2,19	-0,86	True	0,49	0,47	0,12
GARCH	skewt	7 377	7 411	0,03	1,08	- 2,12	2,19	-0,86	True	0,49	0,47	0,12
EGARCH	t	7 377	7 406	0,03	1,06	-2,09	2,15	-0,86	True	0,49	0,44	0,00
EGARCH	skewt	7 379	7 413	0,03	1,06	-2,09	2,15	-0,86	True	0,49	0,44	0,00
GJR-GARCH	normal	7 387	7 415	0,01	1,03	-2,01	2,03	-0,86	True	0,50	0,54	0,26
GARCH	normal	7 443	7 466	0,04	1,08	-2,08	2,17	-0,86	True	0,48	0,47	0,38
EGARCH	normal	7 446	7 468	0,04	1,07	-2,05	2,13	-0,86	True	0,49	0,45	0,09

Tak jak wyjaśniono wyżej, model GJR-GARCH dobrze radzi sobie z asymetrią w zmienności. Rozkład t-Studenta natomiast jest bardziej odpowiedni dla danych, które mają grube ogony (badanie rozkładu danych było przeprowadzone w projekcie 1A i 1B).

W tabeli widać, że w każdej kombinacji modeli warunkowa średnia waha się między 0,01% a 0,04%. Oznacza to, że prognozowana kolejna logarytmiczna stopa zwrotu jest bliska zeru (faktyczna wartość jutro będzie bardzo bliska wartości dzisiaj). Warunkowe odchylenie standardowe natomiast waha się między 1,02 a 1,08, czyli zmienność jednodniowa indeksu WIG20 wynosi około 1%.

Równie małe różnice w otrzymanych wynikach dla poszczególnych 9 modeli są dla przedziałów ufności. Dla najlepszych modeli wynosi on od -2,02 do 2,04. Oznacza to, że oczekiwany jutrzejszy zwrot z 95% pewnością mieści się w granicach +-2%. Rzeczywisty kolejny zwrot dla każdego modelu wynosi -0,86% i dla każdego modelu mieści się w przedziale ufności. Prawdopodobieństwo, że kolejna stopa zwrotu będzie ujemna waha się między 0,48 a 0,50, więc mamy tutaj brak wyraźnej przewagi kierunku zmian w krótkim (jednodniowym) horyzoncie czasowym.

Test Ljung-Boxa dla zestandaryzowanych reszt dla 10 rzędu opóźnienia dla wszystkich modeli osiąga p-value > 0,05, więc nie ma podstaw do odrzucenia hipotezy zerowej mówiącej o braku autokorelacji w resztach. Test ten dla kwadratów reszt również nie odrzuca hipotezy zerowej dla większości modeli (w tym wybranego najlepszego), więc oznacza to, że model “wyczyścił” efekt ARCH/GARCH.

W tabeli rzuca się też to, że wszystkie modele z założeniem o resztach z rozkładu normalnego są na samym dole tabeli (osiągają najgorsze wyniki kryterium informacyjnych - AIC i BIC). Natomiast modele EGARCH zgodnie z testem Ljung-Boxa dla kwadratów reszt nie pozbyły się efektu ARCH/GARCH.

Podsumowanie - bez przesunięć

Dla badanych danych WIG-20 najlepszy okazał się model ARMA(0,0) GJR-GARCH(1,1) z rozkładem t-Studenta. Model ten osiągnął najlepsze wartości kryteriów informacyjnych, nie wskazuje na pozostawienie autokorelacji ani efektu GARCH. Uzyskana warunkowa średnia jest bliska 0, warunkowa wariancja 1%, a przedział ufności to +-2%. Prawdopodobieństwo ujemnego zwrotu wynosi około 0,5.

Dopasowanie modelu ARMA z efektem ARCH w przesuwanych oknach

W tej części projektu kroki są analogiczne do wyżej wykonanego dopasowania modelu. Różnicą są przesuwane okna, których w projekcie zdefiniowano trzy długości - 100, 200 i 500 obserwacji. Na datę początkową przesuwania okien wybrano ostatnią obserwację z 2018 roku. Wartości parametrów modelu ARMA zostały wyznaczone dla każdego kolejnego roku kalendarzowego (wybór p i q ograniczono dla wartości od 0 do 3), kryterium wyboru był

wskaźnik AIC. Następnie, podobnie jak wyżej, zastosowano 3 modele GARCH z 3 różnych rozkładów.

Wyniki dopasowania modelu w przesuwanych oknach

1. Model ARMA

Dopasowanie modelu ARMA w poszczególnych latach dla trzech przesuwanych okien pokazano na dwóch parach wykresów - heatmapie oraz wykresie punktowym, na którym dla ułatwienia interpretacji punkty zostały połączone.

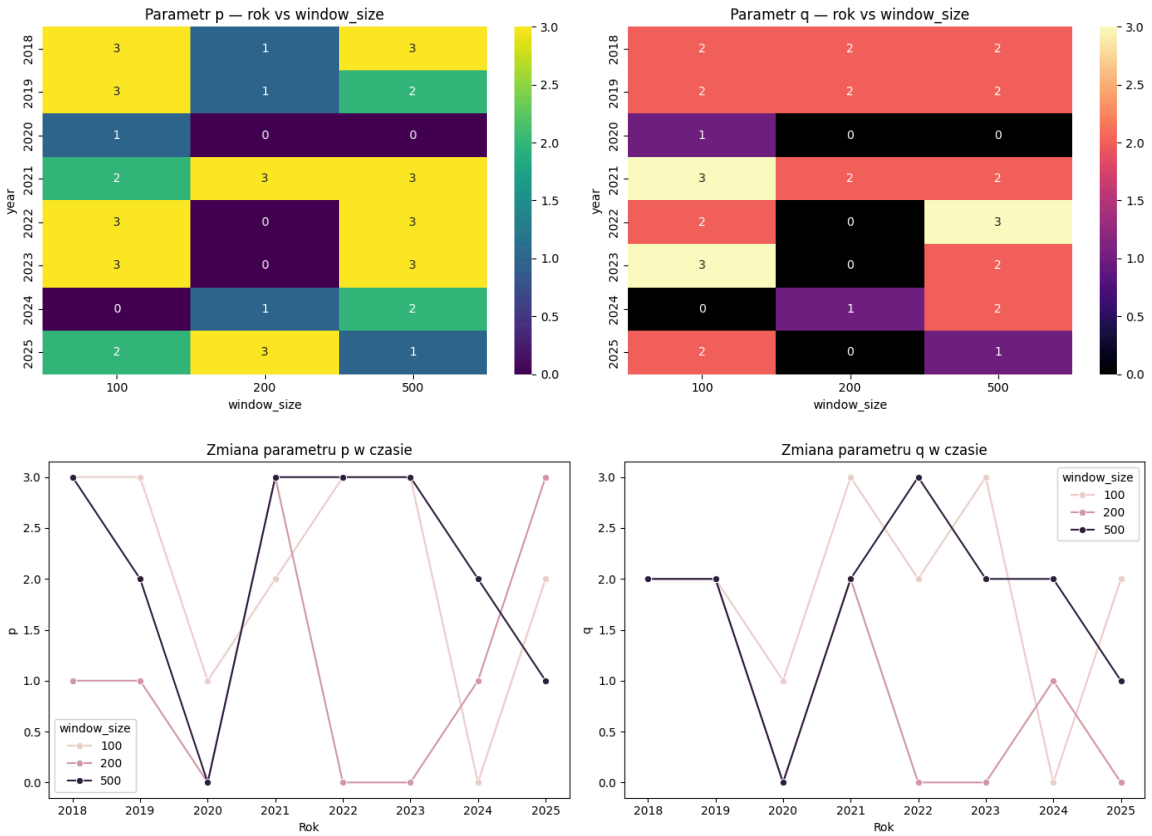

Wykres 1

Na wykresach rzuca się w oczy brak trendu czasowego - wybory parametrów nie wykazują regularnych zmian w wybranych kierunku. W większości lat dominują modele z p=2 lub p=3 oraz z q=2. Model więc zakłada, że wartość zmiennej w chwili t zależy zarówno od poprzednich wartości jak i od poprzednich błędów. Warto tutaj przypomnieć, że badanie zostało zaprogramowane tak, że p i q nie mogły przyjąć wartości wyższej niż 3, więc możliwe, że lepszy okazałby się model o wyższych parametrach. Dla dłuższych okien wybór parametrów jest bardziej stabilny - dla tego okna zdecydowanie dominuje p=3 i q=2. Na zaznaczenie zasługuje jeszcze rok 2020, który jest wyjątkiem od braku trendu czasowego.

W tym roku dla okien 200 i 500 wybrano ARMA(0,0), odpowiadający białemu szumowi - prawdopodobnie z powodu nieprzewidywalności okresu pandemii COVID-19.

2. Efekt ARCH

Ponieważ dla każdego z trzech rozważanych rozmiarów okien estymowano 9 kombinacji modeli GARCH i rozkładów reszt, prezentacja wyników koncentruje się na tym, jak często dana kombinacja była wybierana jako najlepsza (tj. o najniższym AIC) w danym roku i dla danego okna. Oprócz wykresów szczegółowych przedstawiono również zbiorczą tabelę podsumowującą wyniki.

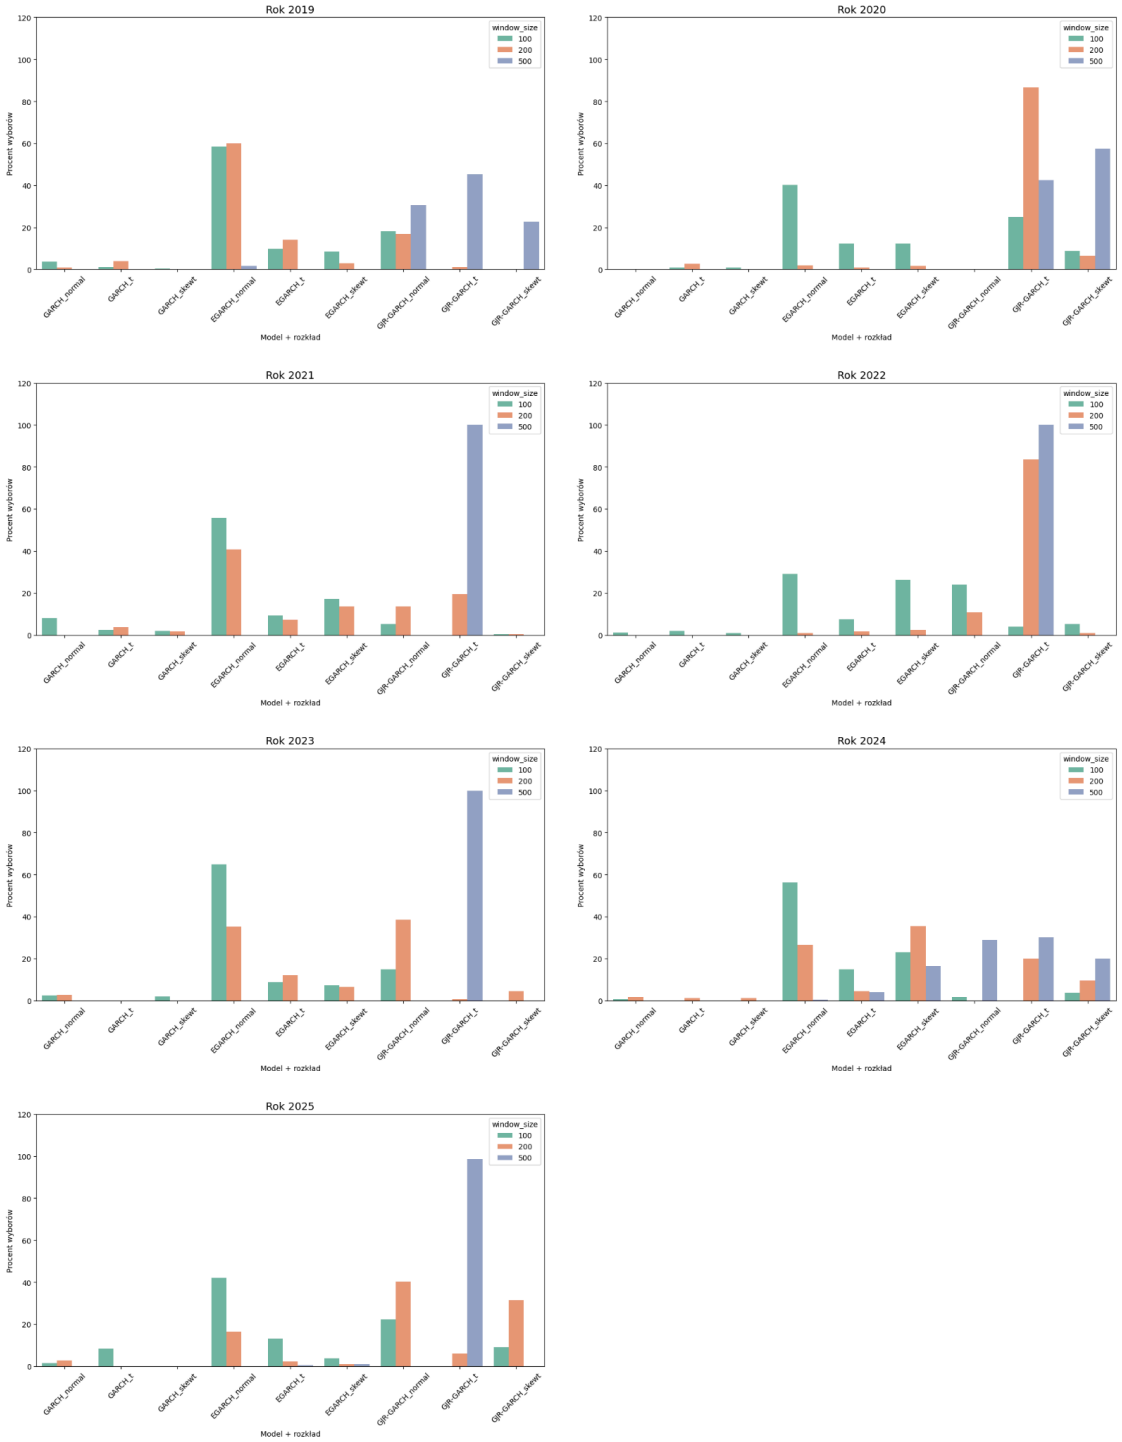

Wykres 2

Okno	2019	2020	2021	2022	2023	2024	2025
100	EGARCH normal	EGARCH normal	EGARCH normal	EGARCH normal	EGARCH normal	EGARCH normal	EGARCH normal
200	EGARCH normal	GJR- GARCH t	EGARCH normal	GJR- GARCH t	GJR- GARCH normal	EGARCH skewt	GJR- GARCH normal
500	GJR- GARCH t	GJR- GARCH skewt	GJR- GARCH t	GJR- GARCH t	GJR- GARCH t	GJR- GARCH t	GJR- GARCH t

Na podstawie wykresów i tabeli można wyciągnąć następujące obserwacje i wnioski:

1. **Modele asymetryczne (EGARCH i GJR-GARCH) zdecydowanie dominują** przy wyborze najlepszych modeli opisujących efekt ARCH. Przewaga modeli EGARCH i GJR-GARCH nad klasycznym GARCH wskazuje, że badane logarytmiczne stopy zwrotów wykazują asymetrię w reakcji na dobre i złe wiadomości (efekt dźwigni). Fakt, że klasyczny GARCH jest wybierany sporadycznie, świadczy o tym, że zwykła wariancja warunkowa jest niewystarczającym opisem dynamiki zmienności w tym przypadku.

2. **Przy najdłuższym oknie (500 obserwacji) najczęściej wybierany jest GJR-GARCH t-Studenta.** Używając długiego okna można wygładzić krótkoterminowy szum i wyłapać stabilne wzorce w zmienności. Dominacja modelu GJR-GARCH nad EGARCH pokazuje, że efekt dźwigni lepiej jest opisywany z zastosowaniem karnego składnika. Silnie preferowany rozkład t-Studenta dowodzi natomiast, że zmienność ma grube ogony, więc silne spadki i wzrosty pojawiają się częściej niż przewiduje to rozkład normalny.

3. **Przy średnim oknie (200 obserwacji) wybory modelu są różne.** Na wykresach widać zdecydowanie większą różnorodność dominujących modeli w poszczególnych latach, jak i brak koncentracji wokół jednego modelu w poszczególnych latach. Jednakże, dominują GJR-GARCH i EGARCH, a klasyczny GARCH wciąż jest marginalny. Widać więc, że badając taki okres czasu modele asymetryczne lepiej wygładzają szum, ale okres ten jest na tyle krótki, że lokalne szoki mają silny wpływ na wybór modelu.

4. **Najkrótsze okno charakteryzuje się przewagą EGARCH normal,** ale inne modele również są wybierane. Modele klasycznego GARCH występują częściej niż w średnim oknie, ale dalej rzadko. Przy tak krótkim oknie czasowym wpływ lokalnych szoków jest zdecydowanie większy. Można więc wywnioskować, że najczęściej wybierany model EGARCH radzi sobie lepiej niż klasyczny GARCH (bo EGARCH reaguje na szoki) i lepiej niż GJR-GARCH (bo EGARCH nie wzmacnia negatywnych szoków). Też przy tak krótkim odcinku rozkład normalny może wystarczająco odpowiadać zmienności (ogony nie zdążyły się zrobić tak grube).

Szczegółowa analiza

1. Przypadki poza przedziałem ufności

W pierwszym kroku dla każdej kombinacji długości okna, modelu (GARCH, EGARCH, GJR-GARCH) oraz przyjętego rozkładu warunkowego wyznaczano 95% przedziały ufności dla kolejnej stopy zwrotu i liczono odsetek przypadków, w których rzeczywista stopa zwrotu znajdowała się poza tym przedziałem. Teoretycznie, dla poprawnie skalibrowanego modelu, około 5% obserwacji powinno wypadać poza 95% przedział ufności.

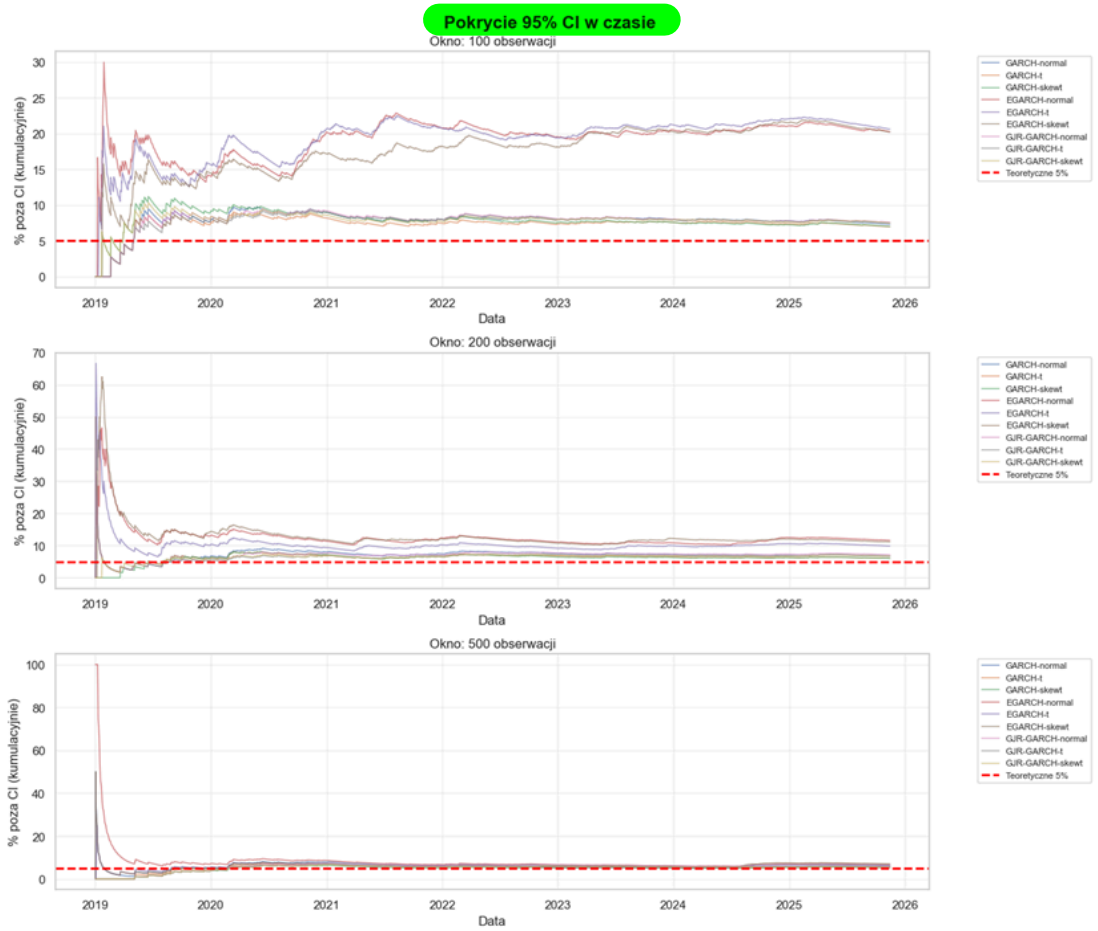

Wykres 3

Na wykresie przedstawiono skumulowany odsetek naruszeń w czasie dla wszystkich zestawień modeli i trzech długości okien estymacji. Mimo że wykres prezentuje naruszenia w formie skumulowanej, ogólne relacje pomiędzy modelami są takie same, jak w przypadku analiz średnich wartości.

Wyniki pokazują, że modele GARCH z rozkładami o grubych ogonach (t-Studenta oraz skośny t) osiągają najniższe poziomy skumulowanych naruszeń, szczególnie w dłuższych oknach (200 i 500 obserwacji), co oznacza, że ich przedziały ufności są najlepiej dopasowane i najbardziej zbliżone do wartości teoretycznej 5% (zaznaczonej na wykresie czerwoną linią przerywaną).

Dla rozkładu normalnego przedziały ufności są wyraźnie zbyt wąskie, co skutkuje znacznie wyższym poziomem naruszeń przykładowo w krótkim oknie (100 obserwacji) wartości te sięgają nawet 10–20%, a w dłuższych oknach utrzymują się wyraźnie powyżej poziomu teoretycznego.

Modele EGARCH i GJR-GARCH, mimo że lepiej opisują asymetrię i efekt dźwigni , również generują wyższe naruszenia niż klasyczny GARCH z rozkładami t-Studenta lub skośnym t-Studenta.

Porównanie naruszeń dolnej i górnej granicy przedziału wskazuje dodatkowo, że w modelach z symetrycznymi rozkładami (normalny, t-Studenta) odsetki naruszeń są zbliżone. Z kolei w specyfikacjach asymetrycznych (np. z rozkładem skośnym t-Studenta lub modelami EGARCH/GJR-GARCH) pojawia się niewielka przewaga naruszeń po stronie dolnej, co odzwierciedla częstsze występowanie dużych spadków niż dużych wzrostów wartości ceny instrumentu.

2. Czasowe wzorce naruszeń przedziałów ufności

W kolejnym kroku analizowano, jak odsetek naruszeń 95% przedziału ufności zmienia się w czasie. Dla każdego roku obliczano, jaki procent obserwacji znajdował się poza przedziałem, osobno dla trzech długości okna. Pozwoliło to zidentyfikować okresy, w których modele są dobrze skalibrowane, oraz takie, w których istotnie niedoszacowują lub przeszacowują ryzyko.

Dla krótkiego okna (100 obserwacji) odsetek naruszeń jest największy i najbardziej zmienny. W okresach podwyższonej zmienności pojawiają się wyraźne piki, co sugeruje, że model nie nadąża za gwałtownymi zmianami reżimu zmienności. Okno 200 obserwacji stanowi kompromis między elastycznością a stabilnością – odsetek naruszeń jest bliższy teoretycznym 5%, a przebieg w czasie bardziej wygładzony. Najdłuższe okno (500 obserwacji) zapewnia najmniejszy przeciętny odsetek naruszeń, lecz reaguje wolniej na nagłe skoki zmienności, przez co w okresach turbulencji pojawiają się serie naruszeń.

Wykresy z analiz przedstawione poniżej dobrze pokazują, że lata o dużej zmienności rynkowej charakteryzują się wyraźnym wzrostem odsetka naruszeń, niezależnie od przyjętej specyfikacji, natomiast w spokojniejszych okresach pokrycie przedziałów jest znacznie lepsze.

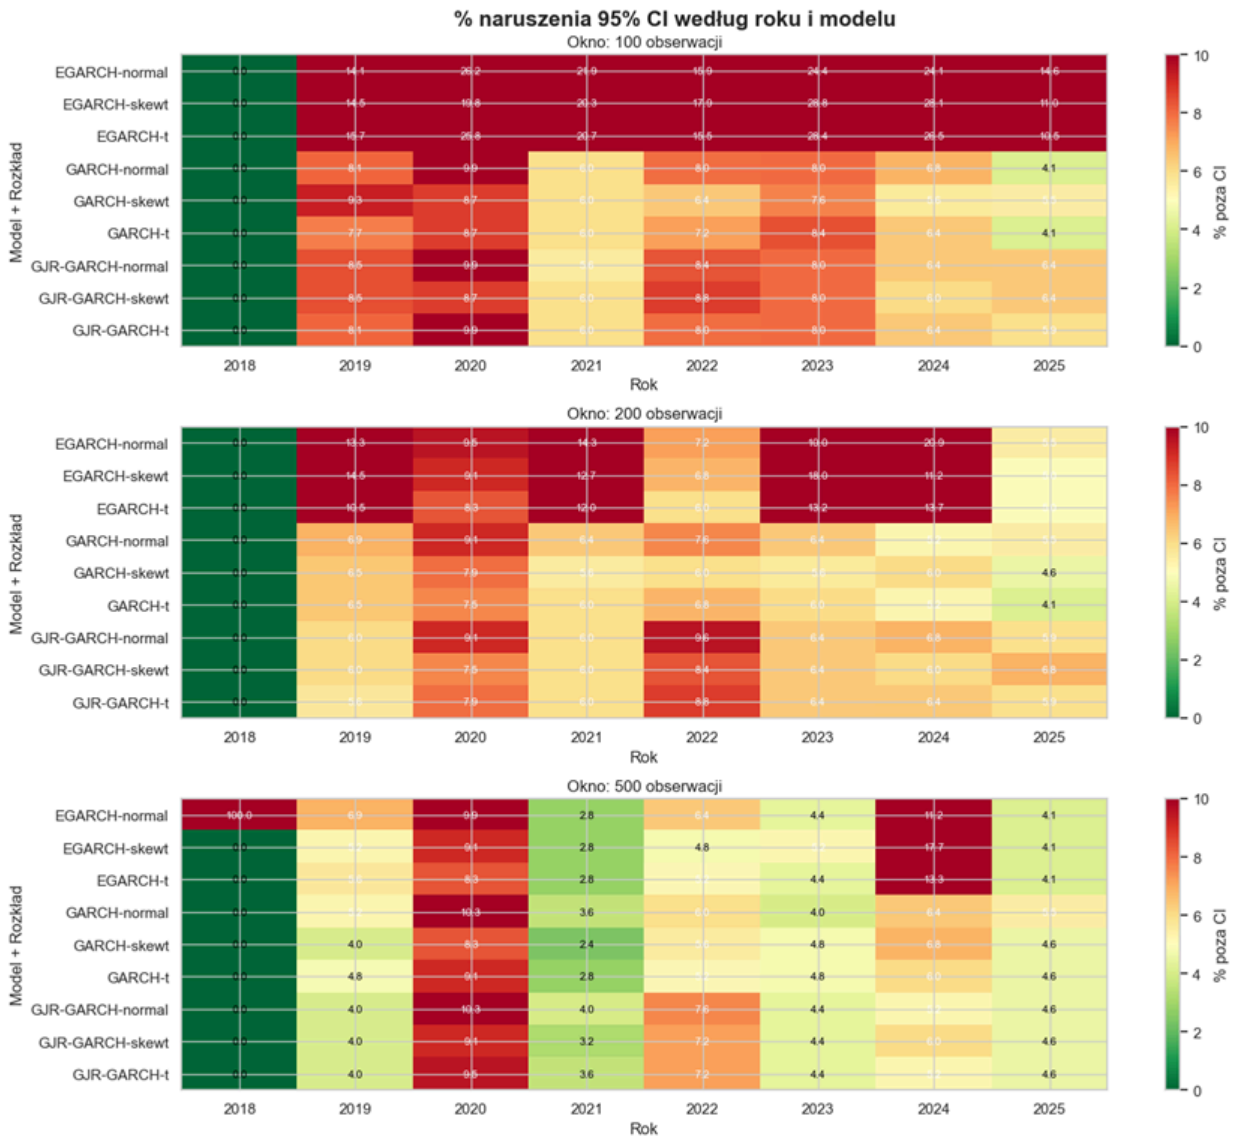

Wykres 4

Dodatkowo, przedstawiona mapa cieplna pozwala precyzyjnie porównać odsetek naruszeń między poszczególnymi latami oraz modelami. Intensywnie czerwone pola wskazują lata, w których modele generowały szczególnie duże odchylenia od teoretycznego poziomu 5%, natomiast odcienie zieleni sygnalizują poprawne i stabilne pokrycie przedziałów. Wykres wyraźnie pokazuje, że krótkie okno (100 obserwacji) charakteryzuje się największymi skokami naruszeń, podczas gdy w oknie 500 obserwacji wartości są najbardziej wygładzone i rzadziej przekraczają poziomy alarmowe. Mapa cieplna dobrze podsumowuje wzorce czasowe — okresy podwyższonej zmienności rynkowej odpowiadają ciemniejszym obszarom, zaś w latach spokojniejszych kolory są wyraźnie jaśniejsze, niezależnie od zastosowanego modelu czy rozkładu.

3. Wpływ wyboru modelu GARCH i rozkładu warunkowego na pokrycie przedziału ufności

Następnie porównano średni odsetek naruszeń 95% przedziału ufności dla wszystkich rozważanych modeli i rozkładów warunkowych, w trzech długościach okna. Celem było wskazanie kombinacji, które zapewniają najlepsze pokrycie przedziału – czyli odsetek naruszeń możliwie bliski wartości 5%.

Z zestawień wynika, że najkorzystniejsze rezultaty uzyskują modele GARCH(1,1) z rozkładami t-Studenta oraz skośnym t-Studenta. Dla tych konfiguracji średni odsetek naruszeń zwykle mieści się w zakresie 5–7%. Zastosowanie rozkładu normalnego w każdej klasie modeli prowadzi do zbyt optymistycznych przedziałów, co objawia się wyraźnie wyższym odsetkiem naruszeń. Modele EGARCH oraz GJR-GARCH, choć lepiej opisują asymetrię reakcji zmienności na dobre i złe informacje, pod względem kalibracji prostych przedziałów ufności wypadają gorzej – naruszeń jest w nich wyraźnie więcej niż w klasycznym GARCH z rozkładem warunkowym t-Studenta.

Z praktycznego punktu widzenia oznacza to, że przy szacowaniu ryzyka skrajnych zmian stóp zwrotu szczególnie użyteczne są modele GARCH z rozkładami t-Studenta lub skośnym t-Studenta, które lepiej odwzorowują grube ogony empirycznych rozkładów.

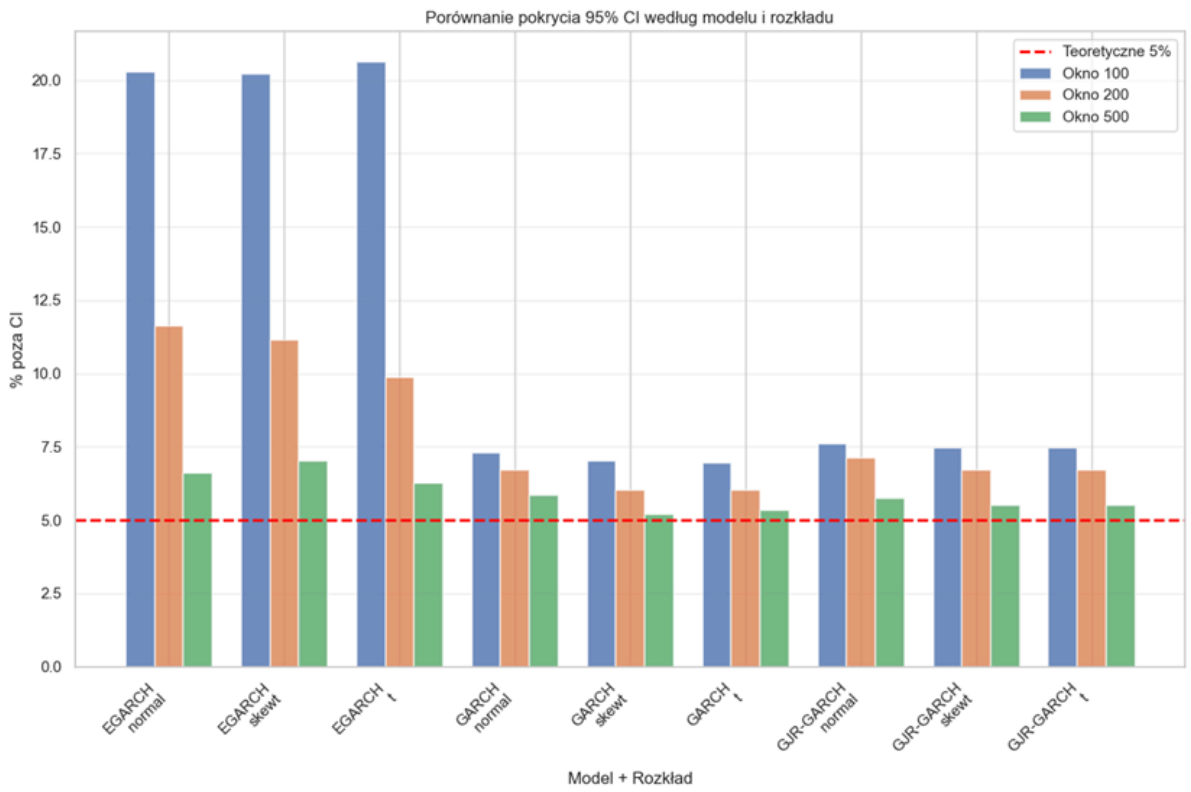

Wykres 5

4. Testy diagnostyczne – zgodność reszt i rozkładu

W ramach oceny dopasowania modeli ARMA–GARCH przeprowadzono testy diagnostyczne reszt: test Ljung–Boxa dla reszt i ich kwadratów oraz test Jarque'a–Bera. Testy te umożliwiają sprawdzenie, czy model prawidłowo usuwa liniowe zależności w średniej i nieliniowe zależności w wariancji oraz czy przyjęty rozkład warunkowy jest zgodny z empirycznym rozkładem reszt.

Test Ljung–Boxa dla samych reszt rzadko wskazuje na istotną autokorelację, co sugeruje, że człon ARMA (równanie średniej opisujące zależność bieżącej stopy zwrotu od jej opóźnień oraz od opóźnionych składników losowych) jest dobrany prawidłowo i usuwa większość zależności w średniej. Częściej odrzucana jest hipoteza o braku efektu ARCH w kwadratach reszt – szczególnie w dłuższych oknach oraz w okresach silnej zmienności rynkowej pozostaje pewna resztkowa heteroskedastyczność.

Wyniki testu Ljung–Boxa dla kwadratów reszt były bardziej zróżnicowane. W wielu oknach, szczególnie dla dłuższych przedziałów estymacji (200 i 500 obserwacji), test wskazywał na obecność heteroskedastyczności. Oznacza to, że niektóre modele nie usuwały w pełni zależności nieliniowych, a dynamika zmienności w danych zmieniała się szybciej, niż zakłada użyta specyfikacja wariancji. Zjawisko to było szczególnie widoczne w okresach podwyższonej zmienności rynkowej, co sugeruje, że modele mogą mieć trudności z odwzorowaniem nagłych skoków zmienności.

Porównując poszczególne specyfikacje, najlepiej wypadał klasyczny GARCH(1,1), który najczęściej eliminował efekt ARCH do poziomu statystycznie nieistotnego. W przypadku modeli EGARCH oraz GJR-GARCH częściej obserwowano pozostałości w strukturze wariancji, mimo że modele te lepiej odwzorowują asymetrię reakcji zmienności.

Test Jarque'a–Bera wykazał, że przy zastosowaniu rozkładu normalnego empiryczny rozkład reszt znacząco odbiega od założeń modelu. Reszty charakteryzowały się podwyższoną kurtozą oraz wyraźną asymetrią, co potwierdza, że rozkład normalny nie jest odpowiedni do modelowania dziennych stóp zwrotu. Dopiero zastosowanie rozkładów o grubych ogonach (t-Studenta oraz skośnego t-Studenta) poprawiało zgodność reszt z założeniami teoretycznymi. W wielu oknach test Jarque'a–Bery nie odrzucał hipotezy zerowej dla modeli GARCH z tymi rozkładami, co potwierdza, że uwzględnienie grubych ogonów znacząco podnosi jakość dopasowania.Warto zwrócić uwagę, że w przypadku testu Jarque'a–Bera to wybór rozkładu warunkowego, a nie konkretnej wersji modelu GARCH (GARCH, EGARCH, GJR-GARCH), miał największy wpływ na zgodność reszt z teorią – różnice między rozkładami były znacznie większe niż różnice między modelami.

Wyniki testów diagnostycznych zmieniały się również w czasie. W bardziej stabilnych okresach reszty lepiej spełniały założenia modeli, natomiast w momentach gwałtownych zmian rynkowych częściej obserwowano odchylenia od zakładanej struktury. Pokazuje to, że jakość dopasowania modeli GARCH jest zależna od bieżącej sytuacji rynkowej oraz że jedna specyfikacja może nie być optymalna w całym badanym okresie.

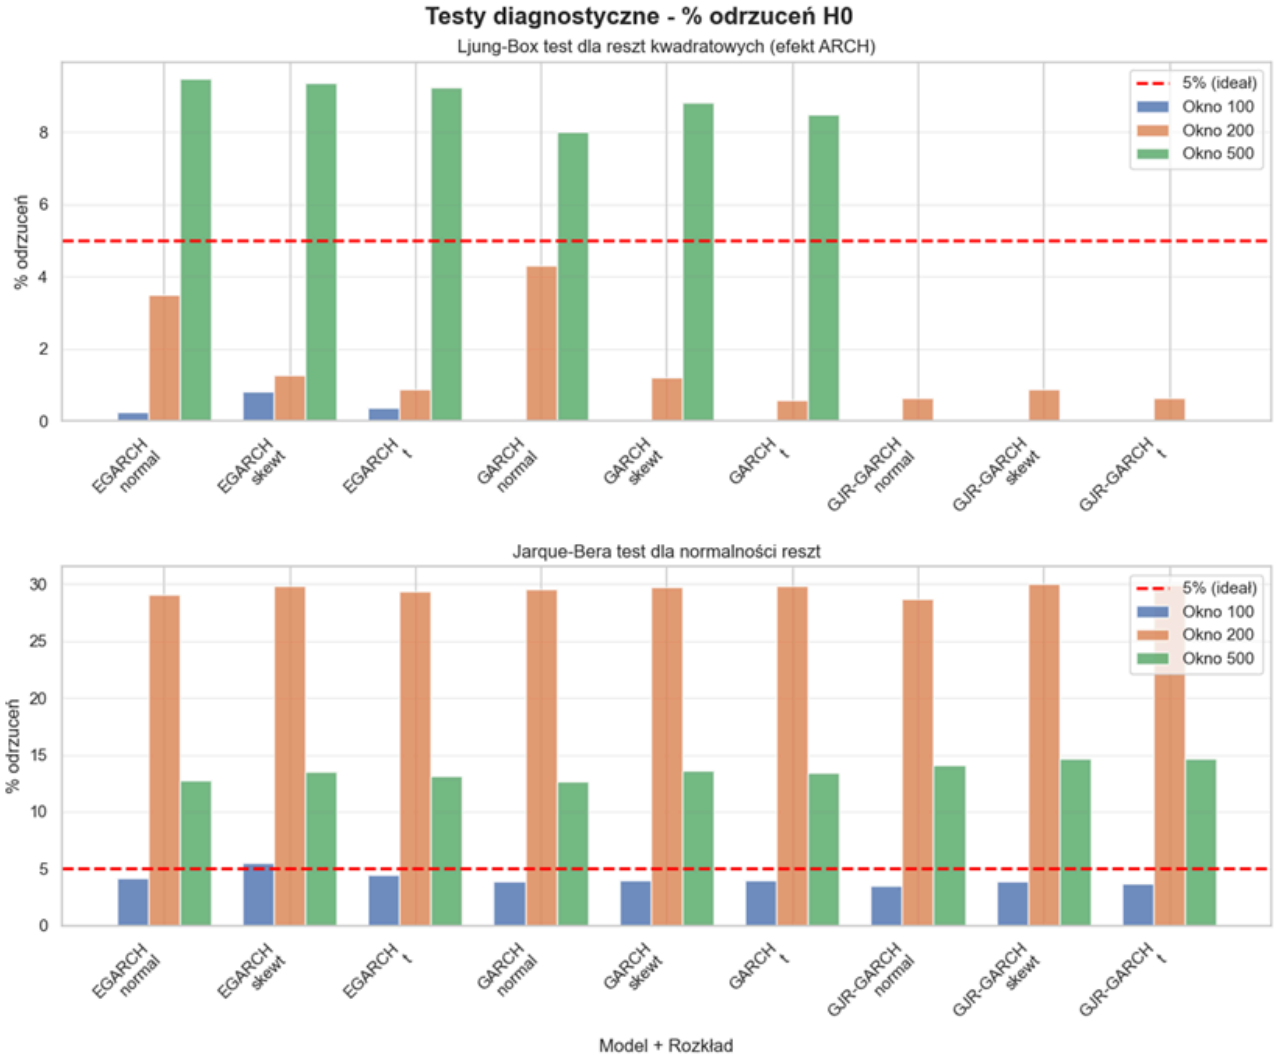

Wykres 6

5. Prawdopodobieństwo spadku P(next < 0)

Celem analizy było zbadanie, czy modele klasy ARMA-GARCH, oprócz prognozowania zmienności (ryzyka), posiadają zdolność przewidywania kierunku zmian cen indeksu WIG20. Weryfikowano hipotezę, że sygnał prawdopodobieństwa spadku jest skuteczniejszy od losowego wyboru.

Analiza statystyczna przeprowadzona na latach 2018–2025 wskazuje, że średnia skuteczność modeli wynosi 49,76%. Wynik ten jest statystycznie nierozróżnialny od losowości (rzut monetą). Oznacza to, że badane modele ekonometryczne nie posiadają systematycznej przewagi w prognozowaniu, czy sesja następnego dnia zakończy się wzrostem czy spadkiem.

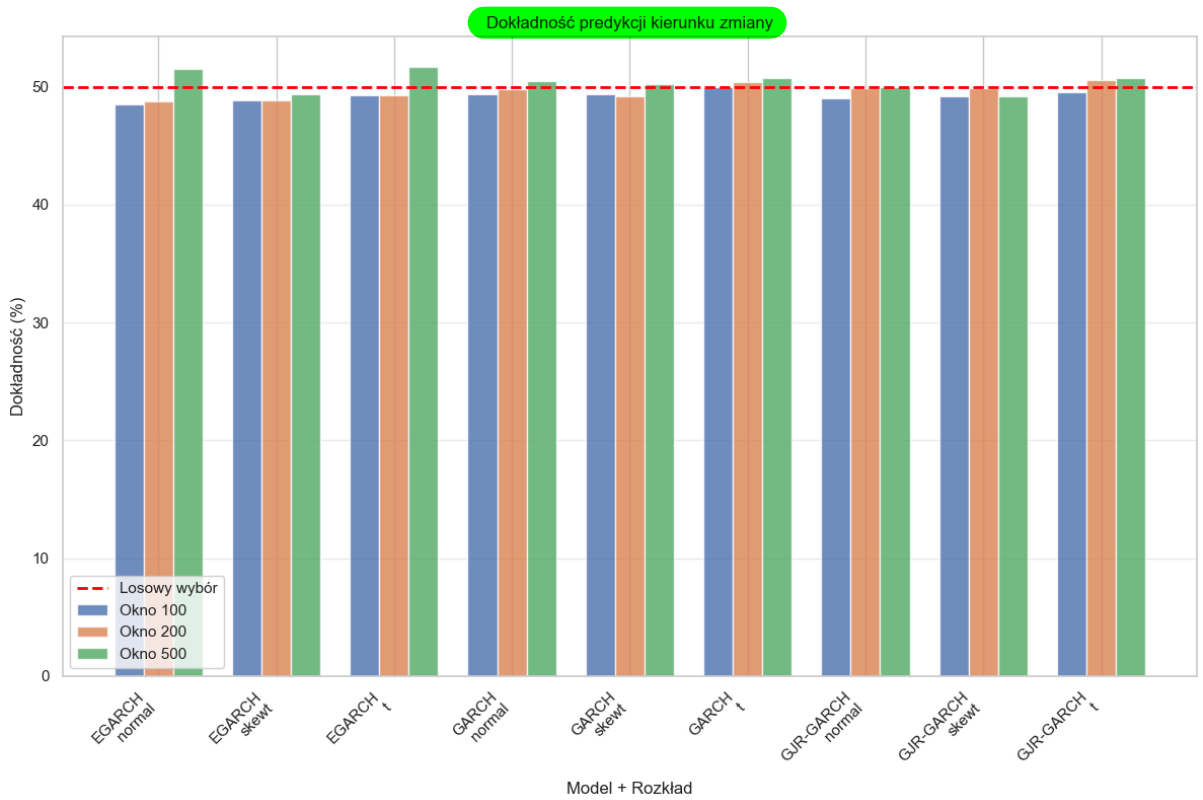

Wykres 8

Wykres słupkowy dokładności predykcji potwierdza wnioski liczbowe - wszystkie słupki dla różnych okien (100, 200, 500) i modeli kończą się w bardzo bliskim sąsiedztwie czerwonej linii 50%. Żadna konfiguracja nie wybija się istotnie powyżej progu losowości. Nawet najlepszy wynik (EGARCH w oknie 500: 51,6%) oferuje przewagę rzędu ~1,6%, co jest wartością zbyt małą, aby np. pokryć koszty transakcyjne w strategii inwestycyjnej.

Model asymetryczny EGARCH jest najbardziej wrażliwy na długość historii: w oknie 500 osiąga najwyższą skuteczność (51,6%), natomiast w oknie 100 notuje najgorszy wynik (48,5% – gorszy od losowości). Świadczy to o trudności w stabilnym oszacowaniu parametrów asymetrii na krótkich próbkach danych. Klasyczny model GARCH wykazuje natomiast mniejszą zmienność wyników między oknami, oscylując stale wokół 49,9%.

Podsumowując, modele GARCH są narzędziami do prognozowania drugiego momentu (wariancji/ryzyka), a nie pierwszego (średniej/kierunku). Wysokie prawdopodobieństwo spadku generowane przez model wynika zazwyczaj z wysokiej zmienności historycznej, a nie z faktycznej predykcji trendu. W związku z tym, sygnały kierunkowe z modelu należy uznać za nieistotne.

6. Zmienność P(next < 0) w czasie

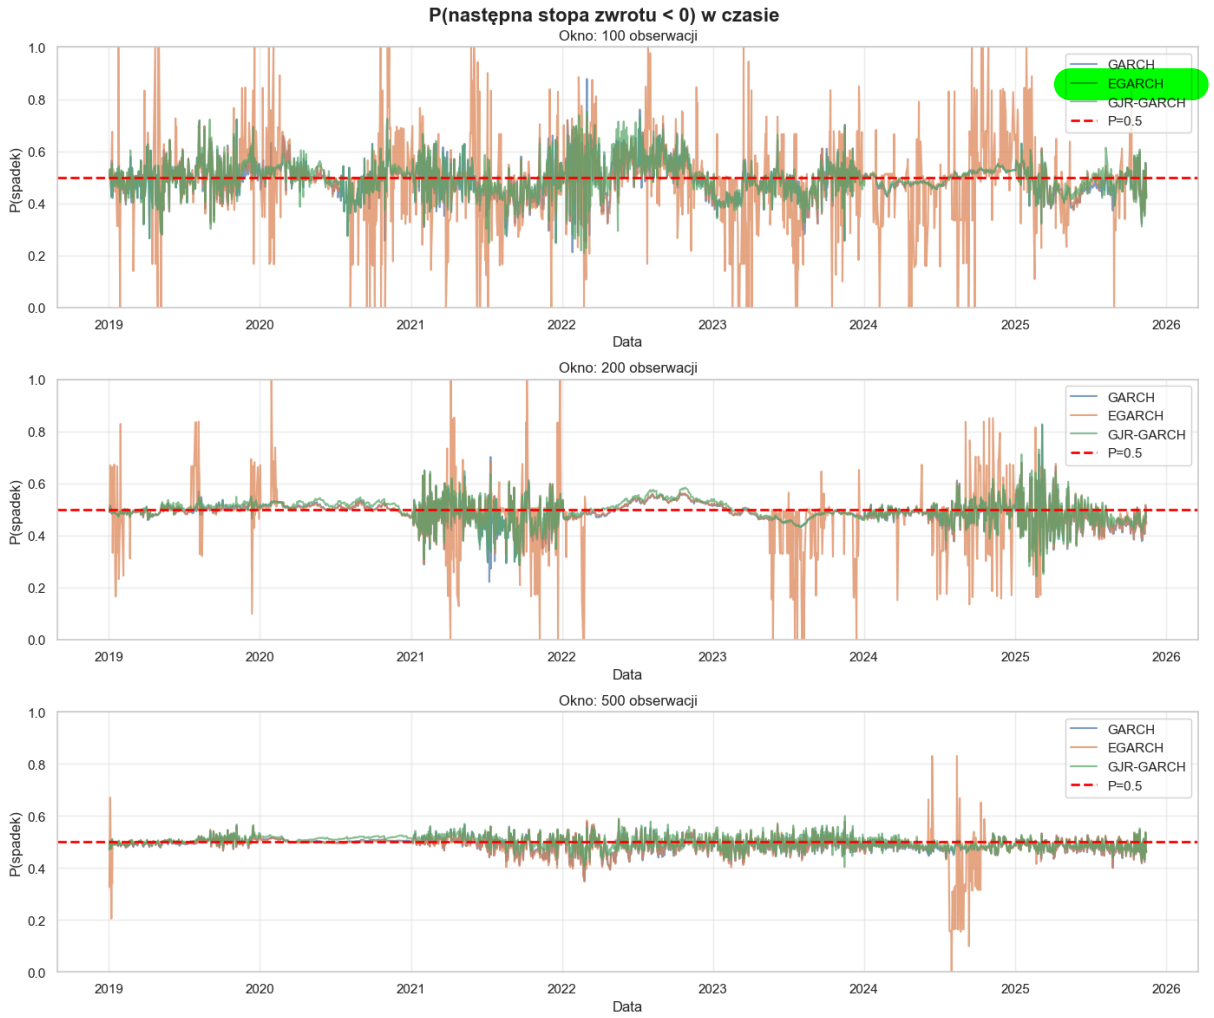

Wykres 9

Okno 100 obserwacji

Pierwszy wykres przedstawia obraz skrajnej niestabilności. Linie nieustannie skaczą od dolnej granicy (blisko 0%) do górnej (blisko 100%). Wykres przypomina "ścianę szumu". Widać wysoką amplitudę wahań. Szczególnie wyróżnia się jedna grupa linii (EGARCH), która zachowuje się najbardziej agresywnie, często dotykając sufitu (1, 0). Oznacza to, że model na podstawie krótkiej historii 100 dni potrafi "uwierzyć", że spadek jutro jest pewny. Biorąc pod uwagę, że skuteczność tych prognoz to ~50% (rzut monetą), jest to klasyczny objaw nadmiernego dopasowania. Model myli szum rynkowy z sygnałem.

Okno 200 obserwacji

Wydłużenie historii do 200 dni łagodzi nieco obraz, ale nie eliminuje problemu. Widać mniej szumu, wciąż dużo "szpilek". Wykres jest czytelniejszy, ale nadal widzimy liczne momenty, w których linie gwałtownie wyskakują powyżej poziomu 80% lub spadają poniżej 20%. Linie różnych modeli często się "rozjeżdżają". W tym samym czasie jeden model może

pokazywać 40%, a inny (np. EGARCH) skacze do 70%. Świadczy to o tym, że przy średnim oknie specyfikacja modelu ma zbyt duży, chaotyczny wpływ na wynik.

Okno 500 obserwacji

Trzeci wykres prezentuje fundamentalnie inną jakość i uzasadnia wybór tego okna. Wszystkie linie (reprezentujące różne modele) są skupione w wąskim paśmie wokół poziomu 0,5 (zazwyczaj między 0,4 a 0,6). Model "zrozumiał", że na efektywnym rynku kierunek zmian jest w dużej mierze losowy. Nie generuje fałszywych alarmów ani złudnej pewności. Warto jednak zwrócić uwagę na rok 2020 - wstęga linii wyraźnie się rozszerza (wzrost niepewności), ale nie eksploduje. Modele sygnalizują większe ryzyko, ale zachowują "zimną krew", nie popadając w skrajności widoczne na wykresie dla okna 100.

7. Szczegółowa analiza przypadków P(next > 0)

Próg Prawdopodobieństwa(P neg >...)	Liczba sygnałów	Skuteczność (Czy faktycznie spadło?)
>0,5 (Lekka przewaga spadków)	20 228	49,7%
> 0,6 (Wyraźny sygnał)	1 692	51,1%
> 0,7 (Silny sygnał)	638	45,5%
> 0,8 (Bardzo silny)	473	45,2%
> 0,9 (Pewny krach)	447	46,3%

Przy umiarkowanych sygnałach (>0,6) skuteczność minimalnie rośnie. Przy sygnałach ekstremalnych (>0,7 i więcej), skuteczność gwałtownie spada poniżej 50%. Oznacza to, że gdy model jest "panicznie pewny" spadku, rynek statystycznie częściej odbija w górę.

Analiza wykazała, że za większość ekstremalnych i błędnych prognoz odpowiada konkretna konfiguracja:

1. Typ Modelu EGARCH: Odpowiada za 85% wszystkich sygnałów powyżej 0,7 (543 przypadki). GJR-GARCH generuje takie sygnały sporadycznie (łącznie 95 przypadków). Wynika z tego, że model EGARCH jest "nadreaktywny". Jego mechanizm wykładniczy w momentach wysokiej zmienności "eksploduje", dając prawdopodobieństwa bliskie 100%, które okazują się błędne.
2. Długość Okna 100: Wygenerowało 78% silnych sygnałów (495 przypadków), podczas gdy okno 500 wygenerowało zaledwie 2% silnych sygnałów (13 przypadków). Dlatego stwierdza się, że długie okno jest odporne na generowanie fałszywych "pewniaków". To krótka pamięć (okno 100) odpowiada za szum informacyjny.

Ekstremalnie wysokie prawdopodobieństwo spadku w modelach GARCH nie powinno być więc interpretowane jako zapowiedź krachu, lecz paradoksalnie jako sygnał możliwego odwrócenia trendu (odbicia). Wynika to z faktu, że model reaguje na przeszłą zmienność – wysokie prawdopodobieństwo pojawia się po dużych spadkach, kiedy rynek jest często wyprzedany.

Dodatkowo, można rozważyć zdyskwalifikowanie modelu EGARCH w oknie 100, ponieważ to właśnie ta konfiguracja jest źródłem największej liczby błędów poznawczych. Model ten z pewnością prognozuje zdarzenia, które nie zachodzą.

Rekomendowane w projekcie okno 500 obserwacji generuje sygnały powyżej 0,7 niezwykle rzadko (tylko 13 razy w ciągu 7 lat). Potwierdza to jego stabilność i konserwatyzm.

Podsumowanie końcowe

Przeprowadzona analiza w oknach kroczących dla indeksu WIG20 w latach 2019–2025 pozwoliła na kompleksową ocenę skuteczności modeli klasy ARMA-GARCH w warunkach rzeczywistego rynku, obejmujących okresy spokoju oraz ekstremalnych szoków (pandemia COVID-19, wybuch wojny).

Główne wnioski z badania:

1. **Kluczowa rola długości okna:**
   Najważniejszym czynnikiem determinującym jakość modelu okazała się długość historii uczenia. Okno 500 obserwacji jest bezwzględnym zwycięzcą. Zapewnia stabilne oszacowanie ryzyka (pokrycie VaR bliskie idealnym 5%), odporność na szum rynkowy oraz poprawne właściwości statystyczne (brak autokorelacji reszt). Okna krótkoterminowe (100 obserwacji) zostały zdyskwalifikowane. Cechują się ekstremalną niestabilnością, generując okresy krytycznego niedoszacowania ryzyka (ponad 20% naruszeń w latach kryzysowych) oraz fałszywą pewność w prognozach.

2. **Rekomendowana specyfikacja modelu:**
   Najlepsze wyniki osiągnął klasyczny model GARCH(1,1) oparty na rozkładzie Skośnym t-Studenta. Rozkład ten najlepiej odzwierciedla naturę polskiego rynku ("grube ogony" i asymetria spadków). Modele EGARCH, mimo teoretycznej przewagi w modelowaniu efektu dźwigni, w praktyce okazały się zbyt reaktywne i niestabilne (szczególnie w krótkich oknach).

3. **Ryzyko vs Kierunek:**
   Badanie ujawniło fundamentalną cechę modeli GARCH:
   - Zarządzanie ryzykiem: Model poprawnie wyznacza "widełki" zmienności, chroniąc portfel przed nieoczekiwanymi stratami.
   - Prognozowanie kierunku: Model jest nieskuteczny. Trafność prognoz wzrostu/spadku wynosi ~50% (poziom losowy). Sygnały o wysokim prawdopodobieństwie spadku często okazywały się mylące.